

PROYECTO INTEGRADOR – MODULO 4

AVANCE GENERAL

Presentado por: Deiberlyn Nin – Dsft09

Roll a desempeñar: Científico de Datos Junior

Contexto:

Tenemos nuestro socio FinanceGuard, quien es un banco digital que ha experimentado un crecimiento exponencial en los últimos años, alcanzando 10000 clientes activos. Sin embargo, la dirección ha detectado un incremento preocupante en la tasa de abandono de clientes (churn), que actualmente alcanza el 20% anual, resultando en pérdidas millonarias. El objetivo principal de negocio para **FinanceGuard** es mitigar el impacto financiero derivado de una tasa de abandono de clientes (**churn**) del **20% anual**, la cual genera pérdidas significativas. Para revertir esta situación, la entidad busca desarrollar un sistema predictivo que identifique a los clientes con mayor probabilidad de irse, con la meta específica de **reducir el churn al 15%** mediante estrategias de retención personalizadas.

Objetivos:

A continuación, se detalla cómo se distribuyeron estos objetivos a lo largo de los tres avances del proyecto:

Avance 1: Fundamentación y Modelo Base

En esta etapa inicial, el enfoque estuvo en la preparación de los datos y el establecimiento de un punto de comparación. Los objetivos incluyeron:

- Investigación y Diagnóstico: Entender el fenómeno del churn bancario y realizar un Análisis Exploratorio de Datos (EDA) para identificar nulos, duplicados y desbalances de clases.
- Implementación de Regresión Logística: Desarrollar el primer modelo supervisado para entender qué variables (demográficas y financieras) influyen en la decisión del cliente, sirviendo como baseline para el proyecto.
- Preprocesamiento: Realizar el encoding de variables categóricas, el split de datos (80/20) y el escalamiento de variables numéricas.

Avance 2: Optimización y Competencia de Modelos

El segundo avance se centró en maximizar la capacidad predictiva mediante algoritmos avanzados. Sus objetivos fueron:

- Entrenamiento de Múltiples Algoritmos: Aplicar técnicas de Gradient Boosting (XGBoost, LightGBM, CatBoost) y otros modelos de ensamble como Random Forest.
- Evaluación Comparativa: Medir y analizar el rendimiento de cada algoritmo usando métricas clave como Accuracy, Precision, Recall, F1-Score y ROC-AUC.
- Selección del Modelo Óptimo: Identificar qué modelo ofrece la mejor solución según la necesidad específica del banco (por ejemplo, priorizar el *Recall* para capturar la mayor cantidad de desertores).

Avance 3: Patrones Ocultos y Enriquecimiento de Datos

El último avance utilizó técnicas de aprendizaje no supervisado para complementar la visión de los modelos anteriores. Sus objetivos fueron:

- Segmentación de Clientes: Aplicar técnicas de clustering (K-Means, DBSCAN) para descubrir grupos con comportamientos diferenciados sin etiquetas previas.
- Reducción de Dimensionalidad: Utilizar PCA y t-SNE para visualizar la estructura de los datos y validar la separación natural de los segmentos.
- Ingeniería de Características (Feature Engineering): Generar nuevas variables derivadas del clustering (como `cluster_risk_priority`) para fortalecer los modelos supervisados finales, permitiendo pasar del análisis descriptivo a la acción estratégica personalizada.

Resumen de comparación entre Modelos:

A continuación, se presenta una síntesis de los resultados obtenidos a lo largo de los tres avances del proyecto de análisis para predecir clientes Churn, del banco digital FinanceGuard:

Avance 1 - Regresión Logística

- **Performance del modelo baseline:** El modelo inicial presentó una **exactitud (Accuracy) del 80.80%** y un **ROC-AUC de 77.48%**. Sin embargo, mostró un desempeño deficiente en la detección de fugas reales con un **Recall de apenas 18.67%**, lo que significa que el 81.33% de los clientes desertores no fueron detectados a tiempo.
- **Interpretabilidad y coeficientes más importantes:**

1. **Factores de Riesgo:** La **Edad (Age)** fue el predictor más crítico; por cada unidad de aumento, los odds de churn se incrementan un **109.35%**. Residir en **Alemania** aumenta el riesgo en un **42.86%** y un mayor **Balance** en cuenta lo eleva en un **17.42%**.
 2. **Factores Protectores:** Ser un **Miembro Activo** reduce la probabilidad de churn en un **40.28%**.
- **Fortalezas y limitaciones identificadas:**
 1. **Fortaleza:** Ofrece una **interpretabilidad clara** y directa a través de los *Odds Ratios* y los intervalos de confianza, permitiendo entender qué variables mueven la probabilidad de fuga.
 2. **Limitación:** Su **incapacidad para capturar patrones no lineales** resultó en un Recall muy bajo, lo que lo hace ineficiente para una estrategia de retención agresiva.

Avance 2 - Gradient Boosting

- **Mejor modelo de boosting identificado:** El XGBoost Hiperparametrizado (**Optimizado**) se identificó como el modelo más sólido y equilibrado para evitar falsas alarmas, logrando un **ROC-AUC de 86.79%**. No obstante, si el objetivo es maximizar la captura de desertores, el **LightGBM** fue el "modelo estrella" con el Recall más alto (49.63%).
- **Feature importance del mejor modelo:** Para el XGBoost optimizado, las variables con mayor capacidad predictiva fueron **IsActiveMember (27.39%)**, **NumOfProducts (26.75%)** y **Age (22.54%)**.
- **Ganancia en performance vs modelo baseline:** Se logró un incremento significativo en la capacidad de discriminación, subiendo el **ROC-AUC de 77.48% (Regresión Logística)** a **86.79% (XGBoost)**, lo que representa una mejora de más de **9 puntos porcentuales**.

Avance 3 - Aprendizaje No Supervisado

- **Segmentos de clientes identificados (K=3):**
 1. **Cluster 0 — "Clientes de Alto Valor / Alemania":** Representa el 100% de la base en Alemania con los saldos más elevados (\$119,730 promedio).
 2. **Cluster 1 — "Base Clientes Francia":** El grupo más numeroso (~50% del total) con saldos moderados.
 3. **Cluster 2 — "Base Clientes España":** 100% de la base en España, con un perfil financiero similar al de Francia.
 4. **Insights de negocio por cluster:** El **Cluster 0** es el **segmento crítico** con una tasa de churn del **32.44%**, superando por 12 puntos la media global. Los Clusters 1 y

2 son segmentos estables con tasas de abandono bajas (~16%), ideales para estrategias de fidelización cruzada.

- **Features derivadas del clustering:** Se creó la variable `cluster_risk_priority`, una escala ordinal (0 a 2) que mapea la pertenencia al cluster con su riesgo histórico de abandono, facilitando cortes más precisos en modelos de árboles.

Lecciones aprendidas

- **¿Cuándo usar modelos supervisados vs no supervisados?**
 1. **Supervisados:** Deben usarse cuando el objetivo es **predecir un evento específico** (como el Churn) basado en datos etiquetados del pasado.
 2. **No Supervisados:** Son ideales para **descubrir estructuras naturales** y patrones ocultos sin etiquetas previas, permitiendo segmentar el mercado y enriquecer el espacio de variables para mejorar modelos supervisados.
- **Consideraciones para futuros proyectos de churn:**
 1. Es crucial realizar un **ajuste de umbral (threshold)** para capturar más falsos negativos si el costo de perder un cliente es muy alto.
 2. Algoritmos como **DBSCAN** pueden tener limitaciones severas en datos tabulares de alta dimensión debido a la dispersión de los datos, siendo **K-Means** más práctico para segmentaciones operativas de negocio.